IR ALÉM 2 | INTELIGÊNCIA ARTIFICIAL EM SÉRIES TEMPORAIS

Classificação tradicional e rede LIF

Grupo Aura | Murilo Salla - RM568041
Elias da Silva de Souza - RM568500 | Julia Duarte de Carvalho - RM567816
FIAP - Inteligência Artificial - Ano 2 | Tutor: Leonardo Ruiz Orabona
Experimento: 27/10/2026 | Revisão técnica: 28/10/2026

1. Objetivo, dados e divisão

Comparamos dois pipelines na classificação de regimes de BPM artificial: regular_simulado (oscilação lenta) e oscilante_simulado (rápida). Damos continuidade aos classificadores da Fase 2 e à cadência IoT da Fase 3, sem usar pacientes Cleveland ou imagens de ECG como séries longitudinais. Os rótulos descrevem o gerador; não identificam doença ou risco clínico.

Geramos 240 sessões de 120 leituras, uma a cada cinco segundos (dez minutos). Ambas as classes compartilham média, amplitude, ruído e deriva; o período varia de 35-65 amostras na classe 0 e 9-18 na classe 1. Fixamos semente 42. Separamos sessões completas, estratificadas: 144 treino, 48 validação e 48 teste. Depois criamos nove janelas de 24 amostras com passo de 12 por sessão, sem compartilhar sessões entre partições.

2. Implementação e seleção dos modelos

Tradicional: regressão logística sobre oito atributos, incluindo média, dispersão, extremos, diferenças sucessivas, autocorrelação e variação final-inicial. **LIF:** reservatório recorrente de 24 neurônios, pesos internos fixos e leitura logística treinada sobre 96 taxas de spikes e 24 potenciais finais. Normalizamos exclusivamente pelo treino; não treinamos sinapses internas por STDP.

Integramos $v \leftarrow v + (dt/tau) \times (-v + I)$, com dt=1 ms, tau=10 ms, limiar 1, reset 0 e refratariedade de 2 ms. Cada leitura corresponde a 20 passos neurais; 20 ms do modelo representam cinco segundos da série. Reiniciamos o estado por janela. Escolhemos C entre 0,01; 0,1; 1; 10 pelo F1 macro da validação, sem ajuste pelo teste. Agregamos as nove probabilidades por média e decidimos em 0,5.

3. Resultados nas mesmas 48 sessões de teste

Métrica / registro	Tradicional	Rede LIF + leitura
Acertos / total	44 / 48	35 / 48
Acurácia balanceada	91,67%	72,92%
F1 macro	0,9165	0,7262
ROC-AUC	0,9722	0,7639
Precisão / recall da classe 1	0,8846 / 0,9583	0,6897 / 0,8333
Matriz: linha real 0; linha real 1	[21, 3]; [1, 23]	[15, 9]; [4, 20]
C escolhido na validação	10	0,01

As matrizes usam classes reais nas linhas e previsões nas colunas. As métricas principais são por sessão; não contamos as 432 janelas sobrepostas como observações independentes. Preservamos probabilidades, divisões e versões para conferência.

4. Análise comparativa e limites

O tradicional errou três sessões regulares e uma oscilante; o LIF, nove e quatro. Os atributos temporais explícitos foram mais úteis neste teste que a representação do reservatório aleatório. O LIF demonstra memória, integração e spikes, mas não apresentou vantagem de classificação. Ambos terminam em leitura logística; a comparação é entre representações de oito e 120 atributos, sem igualdade de capacidade.

Em 2.000 reamostragens estratificadas das sessões de teste, obtivemos IC95 de acurácia balanceada de 83,33-97,92% no tradicional e 60,42-85,42% no LIF. A diferença pareada LIF menos tradicional ficou entre -31,25 e -8,33 pontos percentuais. Isso se limita ao gerador, à semente e ao teste definidos; não demonstra superioridade geral. O bootstrap não cobre outras fontes, pacientes ou sementes.

Medimos transformação e previsão das 432 janelas em CPU: 0.0007 s no tradicional e 0.1178 s no LIF, em uma execução Windows/Python 3.12.10. Tempos variam por máquina e não constituem benchmark repetido. Não medimos consumo de energia, chip neuromórfico ou latência no ESP32. Os sinais não são ECG; a classificação não controla alertas do painel e não valida diagnóstico.

5. Como reproduzir: executar na ordem

1. Preparar: instalar Git e Python 3.12; criar C:\projetos no Explorador. Abrir PowerShell e executar uma linha por vez. Se já há uma cópia, entrar no caminho real e pular o clone. O guia completo contém diagnóstico e resultados esperados.

```
Set-Location -LiteralPath 'C:\projetos'

git clone https://github.com/murilosalla-blip/fiap-ano02-fase03-cardioia.git

Set-Location -LiteralPath '.\fiap-ano02-fase03-cardioia'
```

2. Preparar o ambiente: criar .venv somente se não existir e conferir Python 3.12. Instalar dependências da trilha, sem precisar Node-RED ou Wokwi.

```
python -m venv .venv

.\.venv\Scripts\python.exe -m pip install -r config/fase3/requirements-neuromorfismo.txt
```

3. Executar a comparação: aguardar as duas linhas com F1 macro próximo de 0,9165 e 0,7262 e o retorno do prompt.

```
.\.venv\Scripts\python.exe scripts/fase3/executar_neuromorfismo.py
```

4. Conferir: abrir .tools/runtime/fase3/neuromorfismo no Explorador: series.png, matrizes_confusao.png e atividade_lif.png. Consultar metricas.json e divisao.json. Cada matriz soma 48 sessões.

5. Executar todas as células e visualizar: os comandos abaixo geram uma cópia local e abrem o HTML. Não sobrescrevemos o notebook entregue. O programa termina sozinho; não há servidor para encerrar.

```
.\.venv\Scripts\python.exe scripts/fase3/executar_neuromorfismo.py --notebook

Invoke-Item .tools/runtime/fase3/neuromorfismo/comparacao_temporal_lif.html
```

Conferimos seis testes dos modelos e três de exportação. Concluímos a validação guiada em 28/10 e a revisão técnica deste relatório; as métricas e o hash dos sinais coincidiram. Publicamos o vídeo não listado de 2min59s em 01/11/2026 e conferimos acesso e transcrição automática. A submissão acadêmica permanece pendente.

[1] Gerstner et al., Neuronal Dynamics: LIF e reservoir computing. Adaptamos as equações para uma rede didática própria.
[2] Scikit-learn, prevenção de vazamento.
[3] Notebook comentado e executado | Resultados de referência.